AI Deployment — Renseignement OSINT par NER

Victorien Alleg — MSc 2025-2026

July 7, 2026

CONTENTS

AI Deployment — Déploiement d'une solution d'IA

Renseignement OSINT par NER militaire sur corpus TASS

1. Objectif & pipeline

2. Choix de modélisation

3. Analyse des métriques (jeu de dev, 80/20)

4. Résultats d'inférence — que constate-t-on ?

5. Dashboards Kibana

Top WEAPON — matériel le plus cité

Top MIL_UNIT — unités combattantes

Top MIL_ORG — organisations de haut niveau

Évolution temporelle des mentions

Choix de dashboards & pistes

6. Note de renseignement (courte)

CONFIDENTIAL

AI Deployment — Déploiement d'une solution d'IA

Renseignement OSINT par NER militaire sur corpus TASS

Auteur : Victorien Alleg — MSc 2025-2026 **Dépôt GitHub :** https://github.com/valleg12/osint-ner-tpSMARTPANTS_PRESERVED_41 *(privé — ajouter l'intervenant en collaborateur)*

---

1. Objectif & pipeline

Construire une chaîne de traitement complète qui part de texte brut (corpus d'articles de la rubrique « Guerre » de *tass.com*, format JSON) et aboutit à des dashboards analytiques, afin de repérer des tendances de renseignement : quelles armes sont citées, quelles unités et organisations apparaissent, et comment cela évolue dans le temps.

```
data_set.json ➔ 1. extraction ➔ 2. annotation ➔ 3. fine-tuning NER ➔ 4. inférence ─┬➔ 6a. Elasticsearch
 (corpus TASS)     (texte propre)   (format spaCy)   (en_core_web_sm)      (entités)     └➔ 6b. dashboards Kibana
```

Étape	Entrée → Sortie	Volume
1. Extraction	`data_set.json` → `corpus.jsonl`	21 742 lus → **21 704 conservés**
2. Annotation	`corpus.jsonl` → `annotations.json` (format spaCy)	400 articles, 1 632 entités, offsets validés ✅
3. Fine-tuning	`annotations.json` → `model-best`	split 80/20, transfer learning
4. Inférence	`model-best` → `enriched.jsonl`	**3 000 articles**, 13 502 entités
5. Ingestion	`enriched.jsonl` → Elasticsearch + Kibana	index `osint_articles`

Période couverte par le corpus : 2015-09-07 → 2025-10-26.

CONFIDENTIAL

2. Choix de modélisation

- **Modèle de base :** `en_core_web_sm` (petit modèle anglais de spaCy, léger, rapide, déjà compétent sur les entités génériques). On fait du **transfer learning** (`[components.ner] source = "en_core_web_sm"`) plutôt que d'entraîner un NER vierge.
- **Schéma à 3 labels** : `WEAPON` , `MIL_UNIT` , `MIL_ORG` — assez expressif pour produire du renseignement utile, assez simple pour être annoté et entraîné dans le temps d'un TP.
- **NER plutôt que LLM en production** : coût/vitesse (des milliers d'articles en local sans appel API payant), **déterminisme** (même entrée → même sortie, crucial pour la traçabilité), sortie structurée native, souveraineté. Le LLM est réservé à la **pré-annotation** du dataset d'entraînement ; la validation humaine des offsets reste obligatoire.

3. Analyse des métriques (jeu de dev, 80/20)

Label	Précision	Rappel	F1
Global	0.980	0.966	**0.973**
MIL_ORG	0.991	0.991	0.991
WEAPON	0.991	0.986	0.988
MIL_UNIT	0.846	0.733	0.786

Lecture. Le modèle est très performant sur `WEAPON` et `MIL_ORG` (F1 ≈ 0.99) : ce sont des entités à forte régularité lexicale (noms propres de systèmes d'armes, dénominations officielles d'organisations) que le transfer learning capte vite. `MIL_UNIT` est nettement plus faible (F1 0.79, rappel 0.73) : les unités combattantes ont des frontières ambiguës (« an assault brigade », « the company ») et un vocabulaire plus variable, ce qui correspond exactement aux **limites attendues du NER** (contexte long, formulations ambiguës).

Limite identifiée honnêtement. L'entité la plus fréquente sous `MIL_UNIT` à l'inférence est « *the company* » (111 occurrences) : c'est un **faux positif** récurrent — « company » au sens générique est confondu avec l'unité militaire. Piste d'amélioration : enrichir l'annotation avec des contre-exemples, ou exiger un déterminant numéral/ordinal dans la règle d'annotation.

> Métriques reproductibles depuis `output/model-best/meta.json` .

4. Résultats d'inférence — que constate-t-on ?

Top entités extraites sur 3 000 articles :

CONFIDENTIAL

WEAPON	MIL_ORG	MIL_UNIT
missile (530)	defense ministry (899)	territorial defense brigade (49)
drones (475)	navy (260)	national guard brigade (26)
drone (470)	russian armed forces (217)	marine brigade (20)
artillery (465)	nato (180)	motorized infantry brigade (18)
himars (123)	general staff (91)	…

Tendances.

- Le champ lexical est dominé par **drones + missiles + artillerie** : la guerre décrite par la source est avant tout une guerre de frappes à distance.
- `defense ministry` écrase tout (899) : signature d'un corpus **institutionnel**, fait de communiqués officiels — un signal du biais éditorial autant qu'un fait.
- Présence de matériels occidentaux nommés (`himars`) : la source met en avant l'armement adverse, cohérent avec un cadrage pro-russe.

5. Dashboards Kibana

Les 3 000 articles enrichis ont été ingérés dans **Elasticsearch Serverless** (index `osint_articles`, mapping : entités en `keyword`, `date` en `date`) puis visualisés dans **Kibana (Lens)**. Agrégations `terms` (top 15) pour les entités, `date_histogram` pour la chronologie.

TOP WEAPON — MATÉRIEL LE PLUS CITÉ


Top 15 armes

Quatre systèmes dominent à parts quasi égales (~450-500 mentions : *missile, drones, drone, artillery*), puis décrochage net. La guerre décrite est une **guerre de frappes à distance** ; présence de matériel occidental nommé (*himars*).

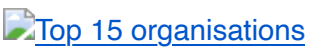
TOP MIL_UNIT — UNITÉS COMBATTANTES


Top 15 unités

Entités plus rares et plus bruitées. La barre de tête *« the company »* (≈79) est le **faux positif** attendu (cf. §3). Les mentions utiles sont des brigades typées (*mechanized / territorial defense / national guard brigade*). La grande barre de droite est le bucket *« Autre »* (queue de distribution).

CONFIDENTIAL

TOP MIL_ORG — ORGANISATIONS DE HAUT NIVEAU



Defense Ministry écrase tout (≈900) : signature d'un corpus **institutionnel** fait de communiqués officiels, suivi de *Navy, Russian Armed Forces, NATO, Aerospace Forces, Black Sea Fleet*. C'est autant un fait qu'un **marqueur du biais de source**.

ÉVOLUTION TEMPORELLE DES MENTIONS



Le sous-corpus analysé (3 000 articles les plus récents) se concentre sur **mi-2024 → fin 2025**, avec un **pic mi-2024** puis une décrue en dents de scie. À noter : l'échantillon étant les articles les plus récents, cette chronologie ne reflète pas toute la profondeur du corpus (2015-2025) mais la période chaude récente — pertinent pour une veille de renseignement.

CHOIX DE DASHBOARDS & PISTES

Ces 4 visualisations répondent aux 3 questions de renseignement du sujet (quelles armes, quelles unités/organisations, quelle évolution). Extensions possibles : **co-occurrences** WEAPON × MIL_UNIT (table croisée `terms`), **filtres par période**, et recherche plein-texte sur `text`.

6. Note de renseignement (courte)

Source & fiabilité. Corpus issu de **TASS**, média d'État russe : biais éditorial fort. On n'extrait pas « la vérité » mais **ce que la source affirme**. La prédominance des communiqués du *defense ministry* confirme un cadrage institutionnel à intégrer dans toute interprétation.

Constats. Sur le sous-corpus analysé (3 000 articles les plus récents, concentrés mi-2024 → fin 2025), le discours de la source est centré sur les **frappes à distance** (drones, missiles, artillerie) et relaie nommément l'armement occidental (HIMARS). Les organisations de haut niveau (ministères, états-majors, marine) structurent le récit, tandis que les unités combattantes précises sont moins fréquemment nommées. Le pic de mi-2024 mériterait un recoupement événementiel.

Limites. Biais de source ; entités sous-représentées ; faiblesse du NER sur les unités (F1 0.79) et faux positifs génériques (« the company »). Les tendances **suggèrent** une orientation du discours, elles ne prouvent pas un ordre de bataille — tout constat doit être recoupé avec des sources indépendantes.

CONFIDENTIAL